

Économétrie des données de panel

M2 Économie de la Santé et Économie Appliquée

Université Paris Cité

Carla Morvan

2026-2027

Part III

Inférence statistique avec des modèles de panel

Inférence statistique avec des modèles de panel

1. Introduction

1.1 Le problème

1.2 Rappel : inférence et erreurs standards

2. Calcul des erreurs standards

2.1 La matrice de variance-covariance des erreurs

2.2 Erreurs standards clusterisées

2.3 Comment ça se calcule

3. Application R

Plan

1. Introduction

1.1 Le problème

1.2 Rappel : inférence et erreurs standards

2. Calcul des erreurs standards

3. Application R

Objectifs du chapitre

- Expliquer pourquoi la structure de panel viole les hypothèses classiques d'inférence des MCO (autocorrélation, hétéroscédasticité)
- Comprendre l'intuition du clustering : pourquoi le nombre d'observations **effectivement indépendantes** n'est pas le nombre de lignes
- Choisir un niveau de clustering pertinent selon le contexte de recherche
- Identifier les limites du clustering en petits échantillons (peu de clusters)
- Calculer et comparer des erreurs standards classiques, robustes et clusterisées sous R (`sandwich`, `clubSandwich`, `fixest`)

Pourquoi les erreurs standards classiques posent problème en panel?

→ Reprenons l'intuition : les MCO supposent que chaque observation apporte une information **nouvelle et indépendante**.

Mais en panel, une même personne, un même pays, un même hôpital... est observé **plusieurs fois**.


→ Si la France a un choc positif imprévu une année (une réforme, une crise), cette perturbation **persiste probablement** l'année suivante → pas totalement une nouvelle information.

→ demander 20 fois son avis à la même personne, ce n'est pas la même chose que demander l'avis de 20 personnes différentes. Pourtant, les MCO classiques traitent ces 20 réponses comme si elles venaient de 20 individus indépendants.


⇒ les erreurs standards classiques **sous-estiment** l'incertitude réelle

Pourquoi les erreurs standards classiques posent problème en panel?

20 individus indépendants



4 individus, 5 fois chacun



Même nombre d'observations, mais une quantité d'information très différente!

Rappel : à quoi sert l'inférence statistique ?

On a un $\hat{\beta}$ estimé sur un échantillon, mais ce n'est qu'une estimation, pas la vraie valeur β .

L'inférence, c'est répondre à

"À quel point puis-je faire confiance à cette estimation ?"

Ça repose sur l'**erreur standard** de $\hat{\beta}$: $se(\hat{\beta}) = \sqrt{Var(\hat{\beta})} \rightarrow$ plus elle est petite, plus $\hat{\beta}$ est précis.

C'est l'erreur standard qui détermine les intervalles de confiance et les p -values. Si elle est **mal calculée**, toute l'inférence qui en découle est fausse (même si $\hat{\beta}$ lui-même est correct).

Rappel : l'hétéroscédasticité

Hypothèse MCO **d'homoscédasticité** : $Var(\varepsilon_i | x_i) = \sigma^2$,
constante pour toutes les observations.

Hétéroscédasticité : la variance de l'erreur **varie** selon les observations $Var(\varepsilon_i | x_i)$ dépend de i (ou de x_i).

Exemple : la variance du temps de trajet domicile-travail est faible pour quelqu'un qui habite en centre-ville (toujours 10-15 min), mais grande pour quelqu'un en périphérie (10 min pas de bouchon, 1h sinon)

Conséquence : $\hat{\beta}$ reste **non biaisé**, mais les erreurs standards classiques sont **fausses** (généralement sous-estimées).

Rappel : l'autocorrélation

Hypothèse MCO : $Cov(\varepsilon_i, \varepsilon_j) = 0$ pour $i \neq j \rightarrow$ les erreurs sont **indépendantes** entre observations.

Autocorrélation : les erreurs sont **corrélées** entre elles. Typiquement, $Cov(\varepsilon_{it}, \varepsilon_{i,t-1}) \neq 0$ pour un même individu à deux périodes proches.

Exemple : si vous avez la jambe cassée, votre temps de trajet est anormalement long aujourd'hui et il le sera encore demain, la semaine prochaine, tant que le plâtre n'est pas retiré.

Conséquence : $\hat{\beta}$ reste non biaisé, mais les erreurs standards classiques **sous-estiment** l'incertitude réelle.

Pourquoi le panel cumule les deux problèmes

La structure de panel favorise **simultanément** :

- **Hétéroscédasticité** entre individus (des pays de tailles, richesses, structures très différentes)
- **Autocorrélation** dans le temps, pour un même individu (chocs persistants, tendances)

Les observations d'un même individu ne sont pas indépendantes entre elles. Le nombre "effectif" d'informations indépendantes est plus proche du nombre d'individus que du nombre total de lignes.

→ Il faut des erreurs standards qui tiennent compte de **ces deux problèmes à la fois**.

Plan

1. Introduction

2. Calcul des erreurs standards

- 2.1 La matrice de variance-covariance des erreurs
- 2.2 Erreurs standards clusterisées
- 2.3 Comment ça se calcule

3. Application R

La matrice de variance-covariance des erreurs

Sous les hypothèses MCO classiques, la matrice de variance-covariance du vecteur d'erreurs ε est :

$$\Omega = \text{Var}(\varepsilon) = \sigma^2 I = \begin{pmatrix} \sigma^2 & 0 & \dots & 0 \\ 0 & \sigma^2 & \dots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \dots & \sigma^2 \end{pmatrix}$$

- **Diagonale constante** (σ^2 partout) : homoscedasticité
- **Hors-diagonale nulle** : pas d'autocorrélation

C'est cette structure très simple ($\Omega = \sigma^2 I$) qui permet la formule classique de $\text{Var}(\hat{\beta}) = \sigma^2 (X'X)^{-1}$.

Cas 1 : hétéroscédasticité seule

$$\Omega = \begin{pmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n^2 \end{pmatrix}$$

La diagonale varie (chaque observation a sa propre variance), mais reste **diagonale**, pas de corrélation entre erreurs.

Solution : l'estimateur robuste de White (*heteroskedasticity-consistent*) → corrige uniquement la diagonale, sans supposer σ^2 constant. C'est le fameux `vcovHC` de R.

Cas 2 : panel hétéroscédasticité + autocorrélation

Avec un panel, les erreurs d'un même individu i sont corrélées entre elles dans le temps $\rightarrow \Omega$ devient **block-diagonale** :

$$\Omega = \begin{pmatrix} \Omega_1 & 0 & \cdots & 0 \\ 0 & \Omega_2 & \cdots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & \Omega_N \end{pmatrix}, \quad \Omega_i = \begin{pmatrix} \sigma_{i1}^2 & \cdot & \cdot \\ \cdot & \sigma_{i2}^2 & \cdot \\ \cdot & \cdot & \sigma_{iT}^2 \end{pmatrix}$$

- Entre individus ($i \neq j$) : toujours 0, on suppose l'indépendance **entre** individus
- À l'intérieur d'un même individu (bloc Ω_i) : termes hors-diagonale **non nuls**, l'autocorrélation


la matrice de White (vcovHC) ne corrige que la diagonale, insuffisant ici. Il faut une correction qui respecte toute la structure par bloc.
 $\Rightarrow$ le clustering des erreurs

L'intuition du clustering

Le clustering ne change pas $\hat{\beta}$, il corrige uniquement le **calcul de l'incertitude** autour de $\hat{\beta}$ (l'erreur standard).

L'idée centrale : le nombre d'observations **effectivement indépendantes** est plus proche du nombre de **clusters** que du nombre total de lignes.

Concrètement, l'erreur standard clusterisée autorise les erreurs ε_{it} à être corrélées **à l'intérieur** d'un cluster (ex. un même pays, dans le temps), tout en restant indépendantes **entre** clusters.



À quel niveau clusteriser ?


Le niveau de clustering est un choix qui dépend de la source de corrélation qu'on soupçonne dans les erreurs.

- **Au niveau individu** (ex: pays) : le choix le plus courant en panel, capture l'autocorrélation temporelle au sein d'un même individu
- **Au niveau d'un groupe de traitement** : essentiel en évaluation de politiques (DiD), si le traitement varie au niveau régional, il faut clusteriser au niveau région, même si les données sont individuelles
- **Multi-way** : parfois on cluster sur **deux dimensions à la fois** (ex. pays *et* année) si les deux sources de corrélation sont plausibles

Principe général : clusteriser au niveau où le **traitement ou le choc varie**, pas seulement au niveau où les données sont structurées.

Niveau 1 : les communes


Unité d'observation : les **communes françaises**, chacune suivie sur 3 périodes.



Chaque cercle : une commune → cluster au niveau communal

Niveau 2 : les intercommunalités


Or chaque commune appartient à une **intercommunalité**. Et si notre outcome dépendait de cette juridiction ?



Les communes d'une même intercommunalité se ressemblent fortement (politiques locales partagées) : **4 groupes nets et compacts**. Bon niveau de clustering.

Niveau 3 : les départements

Nos communes et intercommunalités appartiennent aussi à un niveau de juridiction supérieur, les départements (2 ici).



2 départements, mais **2 paquets incohérents** : les communes regroupées n'ont pas de cohérence. Niveau trop agrégé, signal dilué.

Et si la corrélation vient de deux sources à la fois ?

Jusqu'ici, on a clusterisé sur **une seule dimension** (l'individu).
Mais parfois, deux sources de corrélation coexistent :

- Corrélation **au sein d'un même individu**, dans le temps
- Corrélation **au sein d'une même année**, entre tous les pays (choc qui touche tout le monde en même temps: crise, pandémie)

En 2020, tous les pays de notre panel subissent un choc Covid commun : leurs erreurs cette année-là sont corrélées entre elles, indépendamment du pays. Un clustering par pays seul ne capture pas ça.

→ Il faut alors clusteriser **simultanément** sur pays **et** année : le **clustering two-way**.

La formule : clustering oneway

L'estimateur robuste classique (White) suppose l'indépendance **entre chaque observation**. Le clustering assouplit ça : indépendance seulement **entre clusters**, pas à l'intérieur.

Variance clusterisée (un seul niveau)

$$\widehat{Var}_{\text{cluster}}(\hat{\beta}) = (X'X)^{-1} \left[\sum_{g=1}^G X'_g \hat{u}_g \hat{u}'_g X_g \right] (X'X)^{-1}$$

- $g = 1, \dots, G$: les clusters (ex. les pays)
 - $X_g, \hat{u}_g$: les régresseurs et résidus **de tout le cluster** g
- La somme porte sur les **clusters**, pas sur les observations individuelles

Différence clé avec White : White somme $x_i \hat{u}_i^2 x'_i$ observation par observation. Ici, on somme $X'_g \hat{u}_g \hat{u}'_g X_g \rightarrow$ les résidus **à l'intérieur** d'un cluster peuvent se multiplier entre eux (pas seulement au carré individuellement), ce qui capture la corrélation intra-cluster.

La formule : clustering multi-way

Pour deux dimensions à la fois (ex. pays **et** année) [Cameron, Gelbach & Miller (2011)]:

$$\widehat{Var}_{\text{multi-way}} = \underbrace{\widehat{Var}_{\text{cluster pays}}}_{g=\text{pays}} + \underbrace{\widehat{Var}_{\text{cluster année}}}_{g=\text{année}} - \underbrace{\widehat{Var}_{\text{cluster pays}\times\text{année}}}_{g=\text{pays}\times\text{année}}$$

où $\widehat{Var}_{\text{cluster}}$ est la même formule : $\widehat{Var}_{\text{cluster}} = (X'X)^{-1} \left[\sum_{g=1}^G X'_g \hat{u}_g \hat{u}'_g X_g \right] (X'X)^{-1}$

On applique **trois fois la même recette**, en changeant juste la définition du cluster g : par pays, par année, puis par cellule pays-année (pour corriger le double comptage).

Limites du clustering en petits échantillons

Le clustering repose sur une approximation asymptotique : elle nécessite un nombre **suffisant** de clusters pour être fiable.

Règle empirique courante : en dessous de $\approx 30 - 40$ clusters, les erreurs standards clusterisées peuvent être **mal estimées** (souvent trop petites, malgré la correction).

Dans le cas de l'OCDE : avec 37 pays, on est à la limite basse de cette zone de confort.

Une alternative : le bootstrap

Plutôt que de corriger la formule analytique des erreurs standards, le **bootstrap** estime directement la distribution de $\hat{\beta}$ par rééchantillonnage.

On tire au hasard (avec remise) des **clusters entiers** (pas des observations individuelles), on réestime le modèle sur cet échantillon, et on répète des centaines/milliers de fois. La dispersion des $\hat{\beta}$ obtenus donne directement l'erreur standard.

Ex : On tire au hasard des communes (ou interco en fonction de notre niveau de cluster) et on réestime le modèle des centaines de fois → **l'écart-type de tous ces $\hat{\beta}$** devient l'erreur standard bootstrap.

On tire des **clusters**, pas des lignes → pour respecter la structure de corrélation interne à chaque cluster.

Ex : si le niveau de cluster est l'interco, si un interco est tiré au sort on prend toutes ses années et toutes ses communes.

Ce qu'il faut retenir

- La structure panel viole les hypothèses des MCO sur les erreurs: **hétéroscédasticité** entre individus, **autocorrélation** dans le temps pour un même individu
- Ces deux problèmes rendent les erreurs standards classiques **fausses**.
- Le **clustering** permet de corriger ce problème
- Le niveau de clustering est un **choix de recherche** : il doit correspondre au niveau où la vraie corrélation opère

 le clustering ne change jamais $\hat{\beta}$, seulement notre confiance dans son estimation.

Confusion très commune : cluster vs effet fixe. Un effet fixe **change** $\hat{\beta}$ (il neutralise l'hétérogénéité) ; le clustering **ne change jamais** $\hat{\beta}$, il corrige seulement l'erreur standard autour de ce $\hat{\beta}$.

Effet fixes vs clustering

Effet fixes et clustering sont 2 outils différents, pour 2 problèmes différents.

Effet fixe δ_t ou α_i

- Une variable du modèle
- **Change $\hat{\beta}$**
- Retire le choc commun de l'estimation

Cluster par année ou individu

- Une hypothèse sur l'erreur
- **Ne change jamais $\hat{\beta}$**
- Corrige seulement l'erreur standard

Exemple : δ_t soustrait la météo du jour avant de comparer deux vendeurs de glaces. Le clustering par jour ne change rien aux chiffres, mais reconnaît que les ventes de tous les vendeurs, un même jour de canicule, ne sont pas des informations indépendantes.

Plan

1. Introduction
2. Calcul des erreurs standards
3. Application R

On repart du modèle du chapitre 2

On reprend le modèle à effets fixes retenu au chapitre précédent :

```
fe_plm <- plm(esperance_vie ~ depenses_sante,
              data = pdata, model = "within")
```

'plm' affichait déjà une erreur standard **non corrigée**, c'est celle-ci qu'on va comparer à plusieurs versions corrigées.

Oneway (individual) effect Within Model

Balanced Panel: n = 37, T = 24, N = 888

Coefficients:

	Estimate	Std. Error	t-value	Pr(> t)
depenses_sante	0.00144170	0.00004952	29.113	< 2.2e-16 ***

R-Squared: 0.49929

Adj. R-Squared: 0.47749

Erreurs robustes à l'hétéroscédasticité (White)

```
library(sandwich)  
library(lmtest)
```

```
coeftest(fe_plm, vcov = vcovHC(fe_plm, method = "white1", type =
```

`vcovHC()` calcule la matrice de variance-covariance robuste (White) ; `coeftest()` affiche les coefficients avec cette nouvelle erreur standard. Ne corrige **que** l'hétéroscédasticité, pas l'autocorrélation intra-individu.

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)
depenses_sante	0.00144170	0.00006948	20.75	< 2.2e-16 ***

Quels changements observe-t-on ?

Erreurs clusterisées (niveau pays)

```
coeftest(fe_plm, vcov = vcovHC(fe_plm, method = "arellano",  
cluster = "group"))
```

`vcovHC()` calcule la variance clusterisée, la `method = "arellano"` gère hétéroscédasticité et autocorrélation ensemble, `cluster = "group"` clusterise au niveau individu

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)
depenses_sante	0.00144171	0.00020029	7.198	1.344e-12 ***

Conséquence concrète : le t -value chute d'environ 29 à environ 7 !
Toujours largement significatif, mais l'ampleur de la correction illustre bien pourquoi ignorer le clustering est risqué.

Clustering natif avec fixest

```
fe_fixest <- feols(esperance_vie ~ depenses_sante | pays,
                  data = data_complete,
                  vcov = "cluster")

summary(fe_fixest)
```

fixest clusterise **par défaut** sur la première dimension d'effet fixe (pays ici) dès qu'on utilise feols() avec des effets fixes, pas besoin de packages supplémentaires.

	fe_fixest	fe_fixest_cluster
depenses_sante	0.0014*** (4.95e-5)	0.0014*** (0.0002)
Fixed-Effects:	-----	-----
pays	Yes	Yes
-----	-----	-----
S.E. type	IID	by: pays
Observations	888	888
R2	0.89554	0.89554
Within R2	0.49929	0.49929

Clustering multi-way avec fixest

```
fe_cluster_twoway <- feols(esperance_vie ~ depenses_sante |
                           pays, data = data_complete,
                           vcov = ~pays + annee)

summary(fe_cluster_twoway)
```

vcov = pays + annee applique directement la formule multi-way vue en théorie. fixest gère nativement la combinaison des deux dimensions.

```
      OLS estimation, Dep. Var.: esperance_vie
Observations: 888
Fixed-effects: pays: 37
Standard-errors: Clustered (pays & annee)
               Estimate Std. Error t value Pr(>|t|)
depenses_sante 0.001442   0.000243  5.92151 4.8979e-06 ***
```

Dans notre cas, ça ne change pas grand chose.

Conclusion application

```
etable(fe_fixest, fe_fixest_cluster, fe_cluster_twoway)
```

	fe_fixest	fe_fixest_cluster	fe_cluster_twoway
depenses_sante	0.0014*** (4.95e-5)	0.0014*** (0.0002)	0.0014*** (0.0002)
S.E. type	IID	by: pays	by: pays & annee
R2	0.89554	0.89554	0.89554
Within R2	0.49929	0.49929	0.49929

Le coefficient et les R^2 sont **strictement identiques** : normal, le clustering ne change jamais $\hat{\beta}$ ni l'ajustement du modèle.

Seule l'erreur standard change : de très petite (IID) à 0,0002 (clusterisé) → **4 fois plus grande**.

Le clustering par pays et le clustering pays & année donnent **exactement la même** erreur standard : un signe que la corrélation temporelle résiduelle est négligeable ici.

Quel calcul des erreurs standard appliquer selon le modèle ?

Principe général : en panel, il y a presque toujours de **l'hétéroscédasticité** (problème du panel) on est donc obligé de recalculer les erreurs standards. De plus, le clustering par individu est presque toujours nécessaire : risque **d'autocorrélation** résiduelle.

Modèle	Calcul des erreurs recommandé
Pooled OLS	Au moins White (hétéroscédasticité) ; clustering individu, temps, ou multi-way selon la source de corrélation soupçonnée
Effets fixes (individu)	Au moins individu (autocorrélation dans le temps) ; multi-way si chocs temporels communs suspectés
TWFE	Individu toujours nécessaire , 2-way parfois superflu
Effets aléatoires	White ou individu, cohérent avec la structure de l'erreur $\alpha_i + u_{it}$

Conclusion du chapitre

- La structure panel viole les hypothèses des MCO sur les erreurs : **hétéroscédasticité** entre individus, **autocorrélation** dans le temps pour un même individu
- Ces deux problèmes rendent les erreurs standards classiques **fausses**. Le **clustering** permet de corriger ce problème

→ On a maintenant tous les outils pour **estimer** un modèle de panel et faire une **inférence correcte** dessus.

→ **Reste à identifier un vrai effet causal.**

Les séances suivantes introduisent le modèle de **différences-en-différences** et les **variables instrumentales**, avec au cœur la question de l'endogénéité.