

# Économétrie des données de panel

*M2 Économie de la Santé et Économie Appliquée*

Université Paris Cité

Carla Morvan

2026-2027

# Part IV

## Le modèle de différences-en-différences

# Le modèle de différences-en-différences

## 1. Introduction

- 1.1 Causalité vs corrélation
- 1.2 Les sources d'endogénéité

## 2. Les différences-en-différences

- 2.1 Intuition
- 2.2 Le modèle
- 2.3 L'hypothèse des tendances parallèles

## 3. DiD généralisé

- 3.1 Généralisation
- 3.2 Les problèmes du TWFE avec traitement échelonné
- 3.3 Le DiD dynamique

## 4. Application R

- 4.1 Le cas du dons d'organes en Californie

# Plan

## 1. Introduction

1.1 Causalité vs corrélation

1.2 Les sources d'endogénéité

2. Les différences-en-différences

3. DiD généralisé


4. Application R

## Objectifs du chapitre

- Identifier les principales sources d'**endogénéité**
- Expliquer l'intuition du **contrefactuel** et du modèle de différences-en-différences
- Comprendre l'hypothèse des **tendances parallèles**
- Comprendre les limites du TWFE avec **traitement échelonné** et les solutions récentes de la littérature
- Construire et interpréter un **DiD**


## Corrélation n'est pas causalité : un exemple classique

Chaque été, les ventes de glaces **augmentent**. Chaque été, le nombre de noyades **augmente** aussi. Les deux sont fortement corrélés.




**Faut-il interdire les glaces pour sauver des vies ?**

## Bien sûr que non



## Bien sûr que non



Une troisième variable explique les deux à la fois : la **chaleur estivale**.

La chaleur pousse les gens à **la fois** vers les glaces **et** vers la baignade (donc plus de risques de noyade). Les glaces sont un **facteur de confusion** (*confounder*) qui crée l'illusion d'un lien.

## Corrélation $\neq$ Causalité

En recherche appliquée, on cherche presque toujours à répondre à **une** question précise :

### Quel est l'effet causal de $X$ sur $Y$ ?

"quels sont tous les déterminants de  $Y$  ?" est une question différente, souvent plus vague, qui pousse à tout mettre dans une régression sans réfléchir à l'identification.

Exemple : "quel est l'effet des dépenses de santé sur l'espérance de vie ?" (question causale précise)  $\neq$  "qu'est-ce qui détermine l'espérance de vie ?" (question descriptive, sans stratégie d'identification claire).

## Qu'est-ce que l'endogénéité ?

On vient de voir que **corrélation**  $\neq$  **causalité**. Le nom technique de ce problème : **l'endogénéité**.

**Définition:** Une variable explicative  $X$  est **endogène** si elle est corrélée avec le terme d'erreur :  $Cov(X, \varepsilon) \neq 0$ .

Concrètement, ça veut dire qu'une partie de ce qui explique  $Y$  (contenue dans  $\varepsilon$ ) est aussi liée à  $X$ , donc  $\hat{\beta}$  ne capture pas que l'effet propre de  $X$ , il capture aussi cette partie cachée.

**Dans l'exemple des glaces :**  $X$  = ventes de glaces,  $Y$  = noyades.  
La chaleur (dans  $\varepsilon$ ) est corrélée à  $X \rightarrow X$  est endogène,  $\hat{\beta}$  ne mesure pas l'effet propre des glaces sur la noyade  $\rightarrow$  il est biaisé.

## Source 1 : le facteur confondant

C'est exactement ce qu'on vient de voir avec les glaces et les noyades.

**Définition :** Une troisième variable  $Z$  (souvent inobservée) influence **à la fois**  $X$  et  $Y$ , créant une corrélation entre eux sans lien causal direct.

On l'a déjà rencontré sous un autre nom : l'**hétérogénéité inobservée**  $\alpha_i$ ; comme richesse, institutions, culture... qui affectent à la fois les dépenses de santé et l'espérance de vie.

Les **effets fixes** corrigent ce problème **seulement si**  $Z$  est constante dans le temps pour un même individu.

Si  $Z$  varie dans le temps (ex. une nouvelle politique éducative lancée la même année qu'une réforme de santé), l'effet fixe individuel **ne suffit plus**.  $Z$  reste un facteur confondant actif, même avec effets fixes.

## Source 2 : la causalité inverse

Ce qu'on croit être  $X \rightarrow Y$  peut en réalité être  $Y \rightarrow X$ , ou les deux sens **à la fois** (simultanéité).

**Exemple:** Les dépenses de santé d'un pays  $\rightarrow$  l'espérance de vie mais un pays avec une population plus âgée (donc en moyenne moins d'espérance de vie restante) va aussi **dépenser davantage** en santé. Les deux flèches coexistent.

$\hat{\beta}$  capte un mélange des deux directions de causalité : **impossible de séparer "l'effet de  $X$  sur  $Y$ " de "l'effet de  $Y$  sur  $X$ " avec une simple régression.**

## Source 3 : le biais de sélection

Les individus qui sont analysés ne sont pas choisis au hasard, ils **s'auto-sélectionnent**, souvent selon des caractéristiques liées à  $Y$ .

**Exemple :** compare l'état de santé des patients admis à l'hôpital à celui des patients qui n'y vont pas. On trouve que les patients hospitalisés sont... en moins bonne santé. Faut-il en conclure que **l'hôpital rend malade** ?

$\hat{\beta}$  mélange l'effet du traitement **et** les caractéristiques qui ont poussé ces individus à se sélectionner dans ce groupe.

# Plan

## 1. Introduction

## 2. Les différences-en-différences

### 2.1 Intuition

### 2.2 Le modèle

### 2.3 L'hypothèse des tendances parallèles

## 3. DiD généralisé

## 4. Application R

## Comment répondre à une question causale ?

On a vu 3 sources d'endogénéité qui empêchent une simple régression de répondre à une question causale.

→ Le **DiD** (différences-en-différences) est l'une des méthodes les plus utilisées en économie appliquée pour contourner ce problème.


**L'intuition du DiD** : Imaginez une réforme de santé mise en place dans une seule région, à une date donnée.

- **Groupe traité** : la région qui reçoit la réforme
- **Groupe contrôle** : une région similaire, qui ne reçoit pas la réforme
- **Avant/après** : on observe les deux régions avant et après la réforme

L'idée : le groupe contrôle sert à estimer **ce qui se serait passé** dans la région traitée **si elle n'avait pas reçu la réforme** : le **contrefactuel**.

## Intuition graphique


**Objectif** : estimer l'effet d'une campagne de communication ciblée sur la vaccination



## Intuition graphique

**Objectif** : estimer l'effet d'une campagne de communication ciblée sur la vaccination

**Groupe de traitement** : individus bénéficiaires de la campagne




Comparer seulement pré/post traitement comporte des risques de biais → de nombreux facteurs influencent l'évolution des résultats dans le temps.

## Intuition graphique

**Objectif** : estimer l'effet d'une campagne de communication ciblée sur la vaccination


**Groupe de contrôle** : individus qui ne reçoivent pas (ou pas encore) la campagne



## Intuition graphique

**Objectif** : estimer l'effet d'une campagne de communication ciblée sur la vaccination

**Groupe de contrôle** : individus qui ne reçoivent pas (ou pas encore) la campagne




Comparer seulement traité/contrôle comporte des risques de biais (sélection) : les groupes ne sont peut-être pas comparables au départ.

## Intuition graphique

**Objectif** : estimer l'effet d'une campagne de communication ciblée sur la vaccination

Les différences-en-différences combinent les deux comparaisons :




## Intuition graphique

**Objectif** : estimer l'effet d'une campagne de communication ciblée sur la vaccination

Les différences-en-différences combinent les deux comparaisons :

$$\text{Effet DiD} = (\text{Traité}_{t1} - \text{Traité}_{t0}) - (\text{Contrôle}_{t1} - \text{Contrôle}_{t0})$$



## Le modèle de différences-en-différences

On formalise l'intuition graphique avec une régression :

$$Y_{it} = \beta_0 + \beta_1 \text{Traitement}_i + \beta_2 \text{Post}_t + \beta_3 (\text{Traitement}_i \times \text{Post}_t) + \varepsilon_{it}$$

- $\text{Traitement}_i$  : indicatrice = 1 si l'unité  $i$  appartient au groupe traité, 0 sinon
- $\text{Post}_t$  : indicatrice = 1 si la période  $t$  est après le traitement, 0 sinon
- $\text{Traitement}_i \times \text{Post}_t$  : l'interaction, vaut 1 uniquement pour le groupe traité, après traitement

$\hat{\beta}_3$  est le paramètre d'intérêt : c'est exactement l'**effet DiD** qu'on a calculé graphiquement à la main juste avant.

## Que représente chaque coefficient ?

|                                        | <b>Avant<br/>(Post=0)</b> | <b>Après<br/>(Post=1)</b>               |
|----------------------------------------|---------------------------|-----------------------------------------|
| <b>Contrôle</b><br>(Traite-<br>ment=0) | $\beta_0$                 | $\beta_0 + \beta_2$                     |
| <b>Traité</b><br>(Traite-<br>ment=1)   | $\beta_0 + \beta_1$       | $\beta_0 + \beta_1 + \beta_2 + \beta_3$ |

En faisant la différence des différences à partir de ce tableau, tous les termes s'annulent sauf  $\beta_3$  :

$$\beta_3 = (\text{Traité}_{\text{après}} - \text{Traité}_{\text{avant}}) - (\text{Contrôle}_{\text{après}} - \text{Contrôle}_{\text{avant}})$$

## L'hypothèse des tendances parallèles

L'exercice du DiD repose sur une hypothèse qu'on ne peut jamais prouver directement.

**Hypothèse des tendances parallèles :** En l'**absence** de traitement, le groupe traité et le groupe contrôle auraient suivi la **même évolution** dans le temps.

→ C'est elle qui justifie d'utiliser le contrôle comme contrefactuel : on suppose que sa trajectoire "aurait été" celle du traité, sans le traitement.

Si cette hypothèse est fausse,  $\hat{\beta}_3$  mélange **l'effet du traitement** et **une différence de tendance préexistante** : l'estimation devient biaisée.

## Comment évaluer cette hypothèse ?


On ne peut **jamais prouver** les tendances parallèles (on ne peut pas observer le contrefactuel), mais on peut la rendre **plausible**.

- Regarder les **tendances avant le traitement** : si traité et contrôle évoluaient déjà en parallèle avant, c'est un bon signe
- Si les deux groupes divergeaient **déjà** avant le traitement, l'hypothèse est fragile
- Utiliser plusieurs périodes pré-traitement (pas juste une) pour visualiser la tendance
- **Test placebo** : appliquer le DiD sur une **fausse date** de traitement, antérieure à la vraie. Si on trouve quand même un effet significatif, c'est signe que quelque chose d'autre que le traitement explique la différence.

**Ce n'est pas un test statistique définitif** : c'est un faisceau d'indices, jamais une preuve formelle.


## Tendances parallèles : valides vs violées

### Hypothèse plausible



Même pente avant traitement →  
contrefactuel crédible

### Hypothèse fragile



Pentes déjà différentes avant →  
contrefactuel douteux

# Plan

## 1. Introduction

## 2. Les différences-en-différences

## 3. DiD généralisé

### 3.1 Généralisation

### 3.2 Les problèmes du TWFE avec traitement échelonné

### 3.3 Le DiD dynamique

## 4. Application R

## Au-delà du $2 \times 2$ : plusieurs périodes, plusieurs groupes

Le DiD  $2 \times 2$  (une période avant, une après, un groupe traité, un contrôle) est un cas particulier. En pratique, on a souvent :

- Plusieurs **périodes** avant et après le traitement
- Parfois plusieurs **groupes** traités, à des **dates différentes** (traitement échelonné)

On généralise avec les effets fixes déjà connus : un effet fixe individuel  $\alpha_i$  et un effet fixe temporel  $\delta_t \rightarrow$  exactement le **TWFE**.

## Le modèle TWFE généralisé

$$Y_{it} = \alpha_i + \delta_t + \beta D_{it} + \varepsilon_{it}$$

- $\alpha_i$  **effet fixe individuel** remplace  $\beta_1 \text{Traitement}_i$  du modèle  $2 \times 2$
- $\delta_t$  **effet fixe temporel** remplace  $\beta_2 \text{Post}_t$
- $D_{it}$  **indicatrice de traitement** : = 1 si l'unité  $i$  est traitée à la période  $t$ , 0 sinon

Avec seulement 2 périodes et 2 groupes, ce modèle est **strictement équivalent** au DiD  $2 \times 2$  vu juste avant  $\hat{\beta}$  donne exactement le même résultat que  $\hat{\beta}_3$ .

## Quand le traitement arrive à des dates différentes

Jusqu'ici, on a supposé un traitement qui arrive **en même temps** pour tous les traités. Mais ce n'est pas toujours le cas.

**Traitement échelonné (*staggered treatment*) :** Différents groupes reçoivent le traitement à différentes **dates**, certains tôt, d'autres tard, certains jamais (contrôle pur).

Exemple : une réforme de santé adoptée région par région, sur plusieurs années, pas toutes en même temps.

Découverte récente (2020-2021, Goodman-Bacon ; de Chaisemartin & D'Haultfœuille) : dans ce cas, le TWFE classique peut donner un résultat **biaisé**, voire de **signe opposé** à l'effet réel.


## Pourquoi le TWFE peut se tromper

Goodman-Bacon (2021) montre que le TWFE échelonné est en fait une **moyenne pondérée** de multiples comparaisons DiD  $2 \times 2$ , y compris des comparaisons problématiques.


**Comparaison "interdite"** : un groupe traité **tôt** sert de **contrôle** pour un groupe traité **tard**, alors que le premier groupe est **déjà traité** au moment de la comparaison !

Si l'effet du traitement varie dans le temps (ex. s'accroît avec les années), ces comparaisons interdites reçoivent des **poids négatifs**, elles peuvent inverser le signe de l'estimation globale !!

## Décomposition de Goodman-Bacon




# Décomposition de Goodman-Bacon




$$\hat{\beta}_{TWFE} = \underbrace{w_a \cdot \hat{\beta}_a}_{1er \text{ vs Contrôle}}$$

# Décomposition de Goodman-Bacon




$$\hat{\beta}_{TWFE} = w_a \hat{\beta}_a + \underbrace{w_b \cdot \hat{\beta}_b}_{\text{2eme vs Contrôle}}$$

# Décomposition de Goodman-Bacon



$$\hat{\beta}_{TWFE} = w_a \hat{\beta}_a + w_b \hat{\beta}_b + \underbrace{w_c \cdot \hat{\beta}_c}_{\text{1er vs 2eme, avant}}$$

# Décomposition de Goodman-Bacon



$$\hat{\beta}_{TWFE} = w_a \hat{\beta}_a + w_b \hat{\beta}_b + w_c \hat{\beta}_c + \underbrace{w_d \cdot \hat{\beta}_d}_{\text{comparaison interdite}}$$

## Les solutions de la littérature récente

Plusieurs méthodes proposent de corriger ce problème, en évitant les comparaisons "interdites" :

- **Callaway & Sant'Anna (2021)** : estime des effets DiD groupe par groupe et période par période, puis les agrège proprement
- **de Chaisemartin & D'Haultfœuille (2020)** : propose un estimateur alternatif qui neutralise les comparaisons problématiques
- **Sun & Abraham (2021)** : approche similaire, orientée event-study

## Le DiD dynamique (event-study)

Plutôt qu'un seul effet moyen  $\hat{\beta}$ , on peut estimer un effet **différent pour chaque période** avant et après le traitement.

$$Y_{it} = \alpha_i + \delta_t + \sum_{k \neq -1} \beta_k \mathbb{1}(t - T_i^* = k) + \varepsilon_{it}$$

$k$  = décalage temporel par rapport à la date de traitement  $T_i^*$  ; la période juste avant ( $k = -1$ ) sert de référence omise.

Ça permet de **visualiser** directement les tendances pré-traitement (plutôt que de les supposer) et d'observer comment l'effet évolue dans le temps.

C'est la même chose qu'avant sauf qu'on estime un  $\hat{\beta}$  pour chaque période !

# Plan

1. Introduction
2. Les différences-en-différences
3. DiD généralisé
4. Application R
- 4.1 Le cas du dons d'organes en Californie

## Le cas : dons d'organes en Californie

### Kessler & Roth (2014)

Aux États-Unis, on s'inscrit comme donneur d'organes en cochant une case sur le permis de conduire.

- **Opt-in** (la plupart des États) : par défaut non-donneur, il faut cocher "oui"
- **Choix actif** : la question est posée explicitement, il faut cocher "oui" ou "non"

En juillet 2011, la **Californie** passe de l'opt-in au choix actif. Objectif de la politique : augmenter le taux de dons.

**Configuration DiD** : **Traité** = Californie, **Contrôle** = 25 autres États restés en opt-in. Données trimestrielles, disponibles librement via le package `causaldata`.

## Importer les données et stats descriptives

```
library(tidyverse)
library(fixest)
data_did <- causaldata::organ_donations
```

causaldata est un package qui regroupe les données de réplification de nombreux papiers connus.

→ Avant de commencer les estimations, réalisez quelques graphiques et statistiques descriptives : quelle est la moyenne du taux de don d'organes aux États-Unis ? Y a-t-il de grosses différences selon les États ? Où se place la Californie parmi les autres États ?

## Définir les groupes

→ En observant la base on remarque que le traitement n'est pas clairement identifié.


→ on crée **deux variables séparées**, comme dans le modèle théorique vu plus tôt :

- `traitement = 1` si l'État est la Californie, 0 sinon
- `post = 1` si la période est après juillet 2011, 0 sinon

```
data_did <- data_did %>%  
  mutate(traitement = State == 'California',  
         post = Quarter %in% c('Q32011','Q42011','Q12012'))
```

On retrouve directement les termes du modèle théorique :  $\beta_1 \text{traitement} + \beta_2 \text{post} + \beta_3 (\text{traitement} \times \text{post})$ . C'est cette interaction qu'on va estimer.

## Observations des tendances parallèles



## Estimer le modèle

$$\% \text{donneurs}_{it} = \beta_0 + \beta_1 \text{traitement}_i + \beta_2 \text{post}_t + \beta_3 (\text{traitement}_i \times \text{post}_t) + \varepsilon_{it}$$

```
model_2x2 <- feols(Rate ~ traitement * post,
                  data = data_did, vcov = ~State)
summary(model_2x2)
```

traitement \* post crée automatiquement les 3 termes : traitement, post, et leur interaction traitement:post. Le coefficient sur traitement:post est notre  $\hat{\beta}_3$ , l'effet DiD.

OLS estimation

|                                    | Estimate  | Std. Error | t value           | Pr(> t )       |
|------------------------------------|-----------|------------|-------------------|----------------|
| Observations: 162                  |           |            |                   |                |
| Standard-errors: Clustered (State) |           |            |                   |                |
| (Intercept)                        | 0.444931  | 0.031396   | 14.17146          | 9.6665e-14 *** |
| traitement                         | -0.173597 | 0.031396   | -5.52924          | 8.3624e-06 *** |
| post                               | 0.013926  | 0.006073   | 2.29314           | 3.0176e-02 *   |
| traitement:post                    | -0.022459 | 0.006073   | -3.69832          | 1.0216e-03 **  |
| RMSE: 0.148682                     |           |            | Adj. R2: 0.036196 |                |

## Estimer le TWFE

```
model_TWFE <- feols(Rate ~ traitement * post | State + Quarter,
                    data = data_did, vcov = ~State)
summary(model_TWFE)
```

```
OLS estimation, Fixed-effects: State: 27, Quarter: 6
Observations: 162          Standard-errors: Clustered (State)
              Estimate Std. Error t value Pr(>|t|)
traitement:post -0.022459  0.006131 -3.66304 0.0011185 **
              RMSE: 0.021982      Adj. R2: 0.974196
```

→ qu'est ce qui change ?

Les termes `traitement` et `post` **disparaissent** : ils sont parfaitement colinéaires avec les effets fixes `State` et `Quarter`, qui les absorbent automatiquement. Seule l'interaction reste identifiable — même coefficient qu'en  $2 \times 2$ , mais une erreur standard légèrement différente. Interprétation : effet négatif et significatif. La réforme a fait diminuer le nombre de donneurs d'organes.

## Résultat du test placebo

```
> etable(placebo1, placebo2)
```


|                 | placebo1        | placebo2         |
|-----------------|-----------------|------------------|
| Dependent Var.: | Rate            | Rate             |
| FakeTreat1      | 0.0061 (0.0051) |                  |
| FakeTreat2      |                 | -0.0017 (0.0028) |
| Fixed-Effects:  | -----           | -----            |
| State           | Yes             | Yes              |
| Quarter         | Yes             | Yes              |
| -----           | -----           | -----            |
| S.E.: Clustered | by: State       | by: State        |
| Observations    | 81              | 81               |
| R2              | 0.99377         | 0.99376          |
| Within R2       | 0.00192         | 0.00015          |

Aucun effet significatif détecté à ces **fausses** dates de traitement. Ça soutient l'hypothèse des tendances parallèles : rien d'anormal ne se passait en Californie avant la vraie réforme.

## DiD dynamique : l'effet dans le temps

```
event_study <- feols(Rate ~ i(Quarter_Num, traitement, ref = 3) |
  State + Quarter_Num, data = data_did, vcov = ~State)
iplot(event_study)
```

ref = 3 fixe le dernier trimestre **avant** la réforme comme référence (Q3 2011 = traitement, donc trimestre 3 = juste avant). `i()` crée une indicatrice par trimestre, interagie avec le fait d'être "traitée".



## Lecture du graphique event-study

- **Avant la réforme** (trimestres 1, 2) : coefficients proches de zéro, avec un coefficient significatif — attention, regarder la significativité des coefficients pré-traitement est aussi une forme de test placebo ; ça ne remet pas totalement en cause le design, mais c'est un mauvais signe
- **Après la réforme** (trimestres 4, 5, 6) : effet négatif et stable, environ -2 points de pourcentage à chaque période

L'effet apparaît **immédiatement** après la réforme et reste **stable** dans le temps : pas d'effet différé, pas d'effet qui s'estompe.

⇒ Cette réforme a donc eu un effet non attendu : les individus ont moins adhéré au programme de don d'organes qu'avant la réforme — donner le choix n'a pas accentué l'adhésion.

## Conclusion du chapitre

- Avec le DiD on cherche à identifier un effet causal, pas simplement une corrélation entre deux variables.
- Le **DiD** exploite un groupe traité et un groupe contrôle, avant/après un traitement, pour construire un contrefactuel crédible
- Le **TWFE** généralise le DiD à plusieurs périodes et groupes, mais se dérègle en cas de **traitement échelonné**

Sur notre exemple (dons d'organes) : le résultat est **net et stable** dans le temps, mais un coefficient pré-traitement marginalement significatif rappelle qu'aucun design n'est jamais parfaitement propre.

**Mais que faire si l'endogénéité vient d'ailleurs, sans traitement daté ?**

Le chapitre suivant introduit les **variables instrumentales**, une autre méthode d'identification causale.